

작은 모델이 먼저 답하고, 의심될 때만 큰 모델이 해결한다

출력 신뢰도 + 정답 한 줄 검증을 이용한 적응형 SLM-LLM 라우팅

KSC PILOT · Capability-aware Adaptive Routing

29.15 ms

정답 전용 검증 지연시간

-94.09%

두 번째 호출 지연시간

Qwen2.5-1.5B → 필요할 때만 7B

질문만 보면 '주제'는 알지만, 작은 모델의 '수행 가능성'은 모른다

기존 Query-only 라우팅

질문 임베딩 → 모델 선택

같은 수학 주제 안에서도
쉬운 문제와 어려운 문제를 구분하기 어렵다

본 연구: Output-aware

- SLM이 먼저 실제 답을 생성
- 토큰 확률·엔트로피·형식 등 11개 특징 측정
- 경계 사례만 정답 한 줄로 재검증
- 불일치하거나 불확실할 때만 7B 호출

AUC 0.589 → 0.722

한 번의 짧은 재검증이 Lower 채택과 Upper 전달을 가르친다

Output-aware SLM-LLM routing with answer-only verification



① 신뢰도가 높으면 즉시 채택

② 경계 영역만 Answer-only

③ 불일치·저신뢰만 Upper

c3 기준선은 ②에서 전체 풀이를 다시 생성한다

신뢰도 점수 하나로 세 가지 경로를 선택한다

신뢰도 점수

$$q_i = \sigma(w^T x_i + b)$$

SLM이 맞힐 가능성을
0~1로 출력

즉시 채택

$$q_i \geq \tau_h$$

신뢰도가 높으면 Lower 답 사용

상위 모델 전달

$$q_i < \tau_l$$

신뢰도가 낮으면 Upper 호출

경계 구간

- $\tau_l \leq q_i < \tau_h$ 이면 정답 한 줄 재검증
- 두 답이 같으면 Lower, 다르면 Upper

기호 읽기

- x_i : SLM 출력에서 뽑은 11개 특징
- σ : 점수를 0~1로 바꾸는 sigmoid

두 답의 일치 조건과 실제 호출 비용을 함께 계산한다

최종 채택 여부

accept_i =

Lower 답을 최종
출력할지 결정

높은 신뢰도

$[q_i \geq \tau_h] \vee$

임계값 이상이면 즉시 채택

경계에서 답 일치

$[경계 \wedge \text{답 일치}]$

$a_i^{(1)} = a_i^{(v)}$ 일 때 채택

문항별 비용

- $C_i = C^L + I_i^{(v)}C^V + I_i^{(u)}C^U$
- 1차 SLM + 실제 호출한 검증·Upper 비용

정규화 비용

- $\tilde{C} = (1/N) \sum_i C_i / C^U$
- $C^L=1, C^U=4.667, C^V=0.0591$

Lower의 정답 손실을 회복하면서 Upper 수준의 품질을 지켰다

Lower 단독 기준선

61~63%

GSM8K full/pilot · 비용은
가장 낮음

제안 Cascade

약 86%

Fresh 86.00% · SVAMP C3 86.33%

Always-Upper

87~88%

Fresh 87.25% · SVAMP 88.00%

100문제로 풀어보면


- Lower만 쓰면 약 37~39문제를 놓친다
- 라우팅 후 정답률은 약 86문제까지 회복된다

논문의 정확한 주장

- Upper보다 1.25~1.67%p 낮지만 품질 98%대 유지
- Answer-only도 품질 97.35~99.10%, 비용 19~22% 절감

전체 재풀이를 '답 한 줄'로 바꾸자 검증 시간이 94% 줄었다

Second-pass latency and output length



동일 RTX 3090 · 동일 128문항 · batch 16 · 조건별 2회 ABBA

처리량 2.03 → 34.32 items/s

Upper 품질의 97~99%를 유지하면서 비용을 19~22% 낮췄다

99.10%

인증 분할: Upper 대비 품질 유지

-22.29%

인증 분할: 정규화 비용

97.35%

공식 테스트: Upper 대비 품질 유지

평가	방법	정확도	위험률	비용	절감
인증 250	Answer-only	88.00%	2.80%	0.777	22.29%
테스트 300	Answer-only	85.67%	3.00%	0.806	19.42%
인증 250	C3	88.80%	2.00%	1.008	-0.77%

Always-Upper 비용 = 1.000

결과는 유망하지만, 5% 안전 보장은 아직 통과하지 못했다

관측 위험률

2.80%

7 / 250

95% 단측 상한

5.195%

목표 5.0%보다 +0.195%p

정확도 차이

유의하지 않음

McNemar $p=.625 / .146$


해석해야 하는 것

- 관측된 성능-비용 Pareto frontier 개선
- 비용 감소 신뢰구간은 0을 포함하지 않음

말하면 안 되는 것

- ‘정확도가 동일하다’ 또는 ‘비열등성을 증명했다’
- ‘위험률 5% 이하를 보장한다’

임계값을 높일수록 정확도는 오르지만 비용도 함께 증가한다



사전에 고정한 정책

$$\tau_l = 0.12$$

$$\tau_h = 0.80$$

- 정책 선택 250문항에서만 선택
- 독립 인증 250문항은 이후 한 번 평가
- 0.12/0.82는 사후 참고점

차별점은 '질문'이 아니라 '방금 생성된 답'을 보고 결정하는 것이다

비교	Query-only routing	전체 풀이 cascade	본 연구
판단 신호	질문 임베딩	첫 답 + 전체 재풀이	첫 답 신뢰도 + 정답 한 줄
두 번째 호출	없음	평균 124.55토큰	평균 5.40토큰*
실측 비용	보통 호출 수 중심	검증 오버헤드 큼	1차·검증·Upper를 모두 합산
위험 검증	일반 테스트	일반 테스트	250/250 분리 + 95% 상한
업데이트 대응	분류기 재학습	정책 재학습	임계값 재보정 구조 제안

* 지연시간 벤치마크 128문항 기준

검증된 기여와 앞으로 검증할 구조를 분리한다

이번 파일럿에서 검증

- Answer-only의 GPU 지연시간 94.09% 감소
- 독립 분할에서 품질·비용 효과 재현
- Paired bootstrap·McNemar·정확 위험 상한
- 안전 기준 실패까지 포함한 정직한 보고

운영 확장으로 제안

- Lower 업데이트 후 신뢰도 drift 측정
- 작은 calibration set으로 임계값 재보정
- 위험 상한 제약 아래 비용 최소화

아직 완전한 MLOps 실증 결과로 주장하지 않는다

긴 재풀이 없이도 '믿고 맡길 답'을 고를 수 있다

- Upper 품질 97.35~99.10% 유지 · 검증 29.15ms
- 전체 비용 19.42~22.29% 절감
- 안전 보장은 near-miss - 다음 독립 표본에서 재인증

다음 단계

위험 제약 임계값 최적화
+ 더 큰 표본의 비열등성 검정
+ 다중 모델·도메인 검증

코드·재현 자료: github.com/chjnett/llm_router